

Master Agronomie, AgroParisTech, 2014

Modèle non linéaire

David Makowski
INRA

Rappels sur le modèle linéaire

$$y = \theta_0 + \theta_1 x_1 + \dots + \theta_p x_p + \varepsilon$$

The diagram illustrates the components of the linear model equation $y = \theta_0 + \theta_1 x_1 + \dots + \theta_p x_p + \varepsilon$. Three arrows point from descriptive text below to specific parts of the equation:

- An arrow points from **Variable continue** to the variable y .
- An arrow points from **Combinaison linéaire de paramètres et de variables explicatives continues ou discrètes** to the bracketed term $\theta_0 + \theta_1 x_1 + \dots + \theta_p x_p$.
- An arrow points from **Résidu** to the error term ε .

Rappels sur le modèle linéaire

$$y = \theta_0 + \theta_1 x_1 + \dots + \theta_p x_p + \varepsilon$$

On suppose $E(\varepsilon) = 0$

Conséquence: $E(y) = \theta_0 + \theta_1 x_1 + \dots + \theta_p x_p$

La réponse moyenne est une *combinaison linéaire* des variables explicatives et des paramètres.

Rappels sur le modèle linéaire

Exemples de modèles linéaires:

- Régression linéaire simple.
- Régression linéaire multiple.
- ANOVA.
- Analyse de covariance.

Deux limites du modèle linéaire

- Ne permet pas de modéliser des variables de réponse discrètes (ex: $y=0$ ou $y=1$, comptage...) .
- Ne permet pas de tenir compte d'une relation non linéaire entre la variable de réponse y et les variables explicatives x_1, \dots, x_p .

Deux extensions

- **Le modèle linéaire généralisé**
- **Le modèle non linéaire**

Modèle non linéaire


- Permet d'utiliser une relation non linéaire quelconque entre la variable de réponse y et des variables explicatives x_1-x_p .
- Description plus réaliste des phénomènes.
- Utilisation de paramètres ayant une signification intéressante.
- Calculs plus complexes.

Quatre problèmes liés à l'estimation des paramètres d'un modèle non linéaire

- | | |
|--|---|
| 1. Quels paramètres estimer ? | Paramétrage. |
| 2. Quelle information utiliser ? | Plan d'expérience, répétitions. |
| 3. Quelle méthode d'estimation utiliser ? | Moindres carrés, max. vraisemblance. |
| 4. Précision des estimateurs ? | Variances, corrélations, test. |

Exemple « Maïs »

« Modèle qui simule la longueur du limbe en fonction de la somme de température ».




**Représentation d'un plan de maïs et d'un phytomère
(adapté d'après Scanlon et Freeling 1997).**

Le modèle (pour un phytomère)

$$f(x; \theta) = L_{MIN} e^{R_1(x-T_0)} \quad T_0 < x \leq T_1$$

$$f(x; \theta) = \alpha + \beta(x - T_1) \quad T_1 < x \leq T_2$$

$$f(x; \theta) = L_{MAX} \quad T_2 < x$$



Quels paramètres doit-on estimer ?

Quels paramètres doit-on estimer ?

- *Contraintes pour assurer la continuité de la fonction:*

$$\alpha = L_{MIN} e^{R_1(T_1 - T_0)} \quad L_{MAX} = \alpha + \beta(T_2 - T_1)$$

- *Contrainte pour assurer la continuité de la dérivé entre la première et la deuxième phase:*


$$\beta = L_{MIN} R_1 e^{R_1(T_1 - T_0)}$$

- *On peut fixer L_{MIN} à une valeur initiale.*


→ **Quatre paramètres à estimer : R_1 , T_0 , T_1 , T_2 .**

Quelle information utiliser ?

- Mesures de longueurs de limbe obtenues sur une parcelle pour le 9^{ème} phytomère.
- Mesures réalisées 2 à 3 fois par semaine.
- Une à trois mesures obtenues pour chaque date sur différentes plantes.



Phytomère 9



Quelle méthode d'estimation utiliser ?


1^{er} possibilité : La méthode des moindres carrés ordinaires

Trouver la valeur de θ qui minimise :
$$Z(\theta) = \sum_{i=1}^N [y_i - f(x_i; \theta)]^2$$

Problème :

- le modèle est non linéaire,
- on ne peut pas trouver l'expression analytique des estimateurs.

Appliquer la méthode des MCO avec un algorithme itératif



L'algorithme de Gauss-Newton


1. On définit une valeur initiale $\hat{\theta}_0$

2. On linéarise le modèle par un dév. de Taylor

$$f(x; \theta) \approx f(x; \hat{\theta}_0) + \sum_{j=1}^p \left. \frac{\partial f(x; \theta)}{\partial \theta_j} \right|_{\hat{\theta}_0} (\theta_j - \hat{\theta}_{0j})$$

3. On calcule l'estimateur des moindres carrés avec le modèle linéarisé $\rightarrow \hat{\theta}_1$

4. Retour à l'étape 1 en remplaçant $\hat{\theta}_0$ par $\hat{\theta}_1$.



Arrêt si $\sum_{i=1}^N [y_i - f(x_i; \hat{\theta}_{k+1})]^2 - \sum_{i=1}^N [y_i - f(x_i; \hat{\theta}_k)]^2$ est négligeable.

L'algorithme de Gauss-Newton

Questions

$$f(x; \theta) = e^{\theta x}$$

- Linéariser le modèle à l'aide d'un développement de Taylor

$$f(x; \theta) \approx f(x; \hat{\theta}_0) + \left. \frac{df(x; \theta)}{d\theta} \right|_{\hat{\theta}_0} (\theta - \hat{\theta}_0)$$

- Exprimer le modèle sous la forme : $A + B \theta$

L'algorithme de Gauss-Newton

$$f(x; \theta) = e^{\theta x}$$

$$e^{\theta x} \approx e^{\hat{\theta}_0 x} + (\theta - \hat{\theta}_0) x e^{\hat{\theta}_0 x}$$

$$e^{\theta x} \approx e^{\hat{\theta}_0 x} - \hat{\theta}_0 x e^{\hat{\theta}_0 x} + x e^{\hat{\theta}_0 x} \times \theta$$

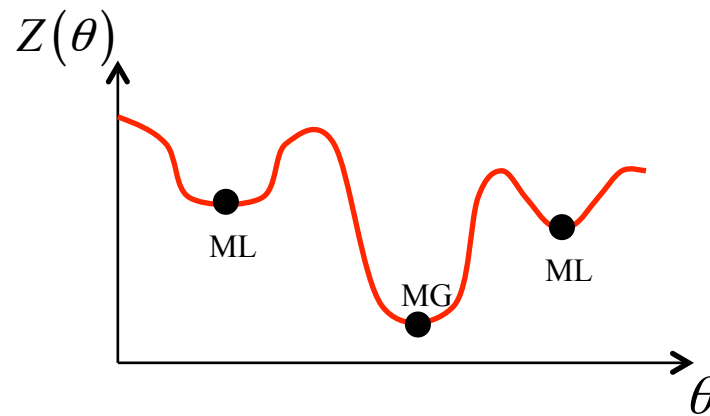
$$\text{Estimateur: } \hat{\theta}_1 = \hat{\theta}_0 + \frac{\sum_{i=1}^N x_i e^{\hat{\theta}_0 x_i} (Y_i - e^{\hat{\theta}_0 x_i})}{\sum_{i=1}^N x_i^2 e^{2\hat{\theta}_0 x_i}}$$

L'algorithme de Gauss-Newton

Aspects pratiques

- On utilise un logiciel statistique (SAS, S+, R, MatLab...)
- On donne en entrée:
 - des données,
 - un modèle,
 - des valeurs initiales des paramètres.
- Le logiciel fournit en sortie les valeurs estimées des paramètres.

Minimum locaux et minimum globaux



→ Essayez plusieurs valeurs initiales !

Quelle méthode d'estimation utiliser ?

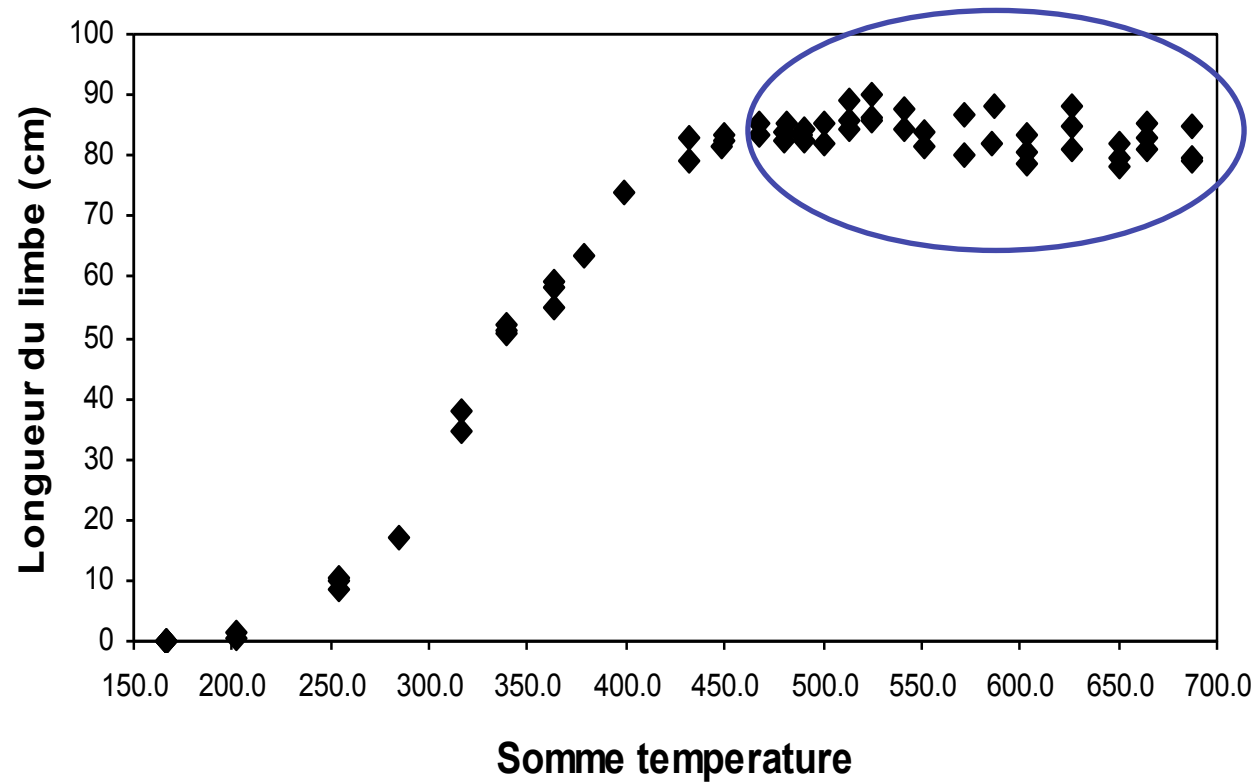
1^{er} possibilité : La méthode des moindres carrés ordinaires

Trouver la valeur de θ qui minimise :
$$Z(\theta) = \sum_{i=1}^N [y_i - f(x_i; \theta)]^2$$

Inconvénient :

- Les estimateurs ne sont pas de variances minimales si les résidus ont des variances hétérogènes.
- Or ici, les erreurs de mesures sont plus grandes pour les limbes de grandes tailles.

Variance plus grande ici.



Quelle méthode d'estimation utiliser ?

La méthode des moindres carrés pondérés



Trouver la valeur de θ qui minimise :
$$Z(\theta) = \sum_{i=1}^N \frac{[y_i - f(x_i; \theta)]^2}{\sigma_i^2}$$

avec
$$\sigma_i^2 = \frac{1}{K-1} \sum_{k=1}^K (y_{ik} - \bar{y}_{i\cdot})^2$$

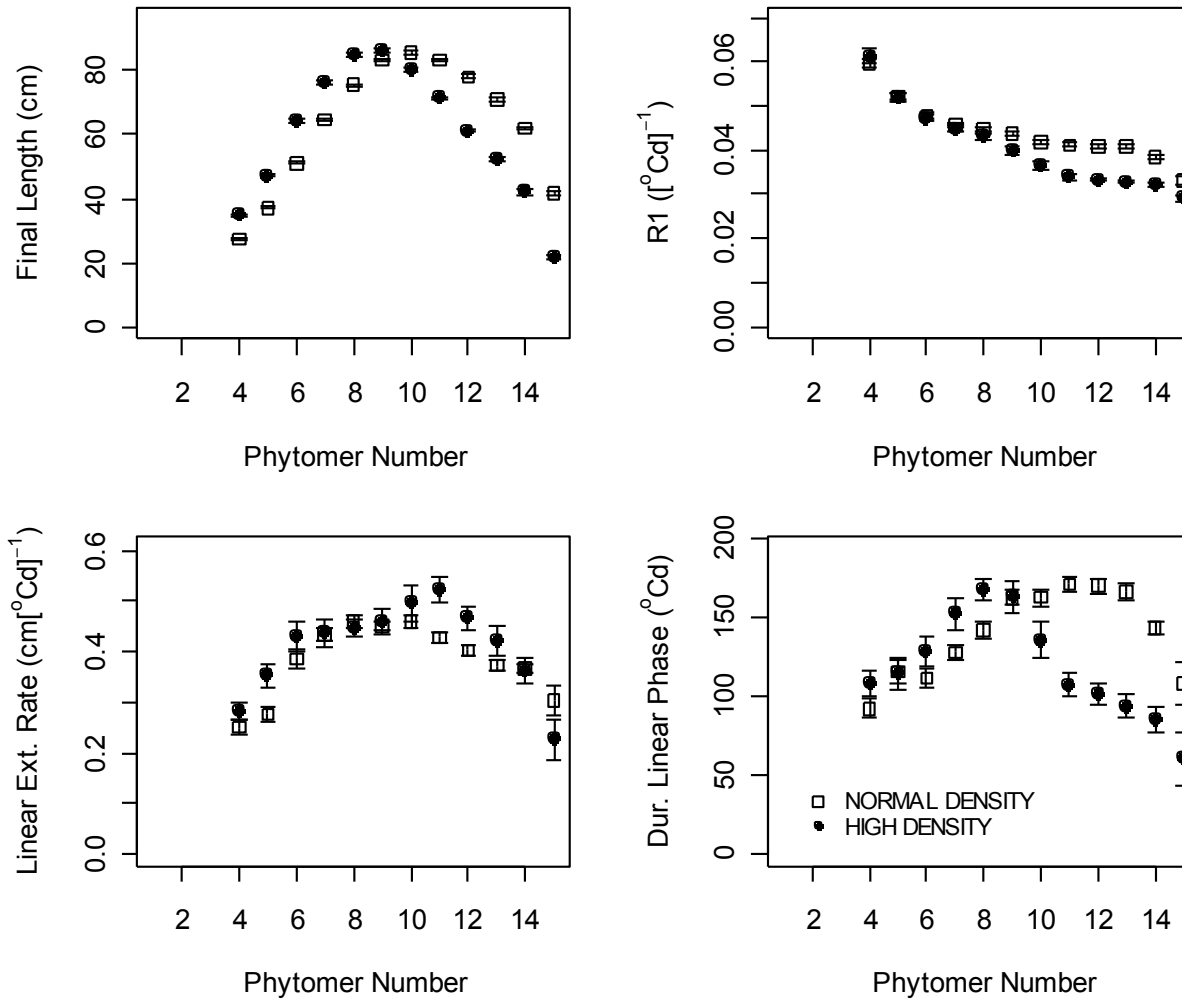
Définir la variance des résidus comme une fonction croissante de la longueur du limbe

$$\text{var} [y_i - f(x_i; \theta)] = \sigma^2 f(x_i; \theta)^\tau$$

On estime θ , σ et τ à partir des données.



Ces estimateurs sont-ils précis ?



Utilisation de R pour estimer les paramètres d'un modèle non linéaire

```
Fit<-nls(y~FONCTION(x, Theta0, Theta1, Theta2),  
        start=list(Theta0=9, Theta1=0.04, Theta2=100),  
        data=TAB)  
  
summary(Fit)  
  
coef(Fit)
```

Exemple « fertilisation du blé »




Quelle dose d'engrais N appliquer ?

2. Modèle non linéaire

Exemples de modèles pour optimiser la dose d'engrais

Model linéaire


$$z = \theta_0 + \theta_1 x + \theta_2 x^2$$



Model non linéaire

$$z = \theta_0 \text{ if } x \geq \theta_2$$

$$z = \theta_0 + \theta_1 (x - \theta_2) \text{ if } x < \theta_2$$



2. Modèle non linéaire

Les données

<code>x <- c(0, 50, 100, 200, 250, 300)</code>	<code>#Values of x (fertilizer dose)</code>
<code>y<- c(5.1, 7.5, 9.2, 9.8, 9.6, 9.7)</code>	<code>#Values of y (yield)</code>
<code>TAB<-data.frame(x, y)</code>	<code>#dataset TAB</code>
<code>TAB</code>	<code>#print the dataset TAB</code>
<code>TAB\$x</code>	<code>#column x of TAB</code>
<code>TAB\$y</code>	<code>#column y of TAB</code>
<code>x</code>	<code>#column x of TAB</code>
<code>y</code>	<code>#column y of TAB</code>

2. Modèle non linéaire

Estimation des paramètres – modèle linéaire

```
x2<-x*x                                # New variable
Fit<-lm(y~x+x2)                         # Parameter estimation by least squares
                                         # for the quadratic model

summary(Fit)                            # Results
coef(Fit)                               # The three estimated parameter values
Parameters<-coef(Fit)


X11()                                    #New window
par(mfrow=c(1,1))

plot(x,y, xlab="Fertilizer dose (kg/ha)", ylab="Yield (t/ha)", pch=19, ylim=c(4,11))

Pred<-Parameters[1]+Parameters[2]*(0:300)+Parameters[3]*(0:300)^2

lines(0:300, Pred, lty=4)
```

2. Modèle non linéaire



2. Modèle non linéaire

Estimation des paramètres – modèle non linéaire

```
LP<-function(d, Theta0, Theta1, Theta2) {  
  Y<-Theta0+Theta1*(d-Theta2)  
  Y[d>=Theta2]<-Theta0  
  return(Y)  
}
```

```
Fit<-nls(y~LP(x, Theta0, Theta1, Theta2), start=list(Theta0=9, Theta1=0.04,  
Theta2=100), data=TAB)
```


```
summary(Fit)
```

```
Parameters<-coef(Fit)
```


```
Pred<-Parameters[1]+Parameters[2]*(0:300-Parameters[3])  
Pred[Pred>Parameters[1]]<-Parameters[1]
```

```
lines(0:300, Pred)
```

2. Modèle non linéaire



2. Modèle non linéaire



2. Modèle non linéaire

```
QP<-function(d, Theta0, Theta1, Theta2) {  
  Y<-Theta0+Theta1*(d-Theta2)^2  
  Y[d>=Theta2]<-Theta0  
  return(Y)  
}
```

```
Fit<-nls(y~QP(x, Theta0, Theta1, Theta2), start=list(Theta0=9,  
Theta1=-0.004, Theta2=100), data=TAB)
```


```
summary(Fit)
```

```
Parameters<-coef(Fit)
```

```
Pred<-Parameters[1]+Parameters[2]*(0:300-Parameters[3])^2  
Pred[0:300>Parameters[3]]<-Parameters[1]
```

```
lines(0:300, Pred, lwd=2)
```

2. Modèle non linéaire



Conclusions

- Le modèle linéaire ne permet pas de traiter tous les problèmes pratiques.
- Le modèle **linéaire généralisé** permet de traiter le cas des variables de réponse discrètes, notamment binaires.
- Le modèle **non linéaire** permet souvent de décrire de façon plus réaliste un phénomène physique ou biologique.
- Les paramètres de ces modèles peuvent être estimés à l'aide de logiciel statistiques.
- L'estimation des paramètres des modèles non linéaires est parfois délicate à mettre en œuvre.

Quelques références

Agresti A. 1990. *Categorical data analysis*. Wiley

Makowski D, Monod H. 2011. *Analyse statistique des risques agro-environnementaux*. Springer

McCulloch C.E., Searle S.R. 2001. *Generalized, linear, and mixed models*. Wiley

Seber GAF, Wild CJ. 2003. *Nonlinear regression*. Wiley.

Wallach D, Makowski D, Jones JW. 2006. *Working with dynamic crop models*. Elsevier.



Collection
Statistique
et probabilités
appliquées

Dirigée par
Yadolah Dodge

COMITÉ ÉDITORIAL :

Aurore Delaigle

Université de Melbourne, Australie

Christian Genest

Université McGill, Montréal

Marc Hallin

Université libre de Bruxelles, Belgique

Ludovic Lebart

Télécom-ParisTech, Paris

Christian Mazza

Université de Fribourg, Suisse

Stephan Morgenthaler

EPFL, Lausanne

Louis-Paul Rivest

Université Laval, Québec

Gilbert Saporta

CNAM, Paris

David Makowski, Hervé Monod

Analyse statistique des risques agro-environnementaux

Études de cas

Cette collection met à la disposition du public intéressé par la statistique (étudiants, enseignants, chercheurs) des ouvrages qui concilient effort pédagogique et travail permanent de mise à jour. Cette démarche implique de prendre en compte les renouvellements des concepts, des champs d'application et des outils de traitement. Seules une compréhension profonde et une appropriation des connaissances permettront de s'adapter aux évolutions qui n'ont pas fini de bouleverser cette discipline.

00 € TTC

ISBN : 978-2-8178-0250-3



9 782817 802503

springer.com



Collection
Statistique
et probabilités
appliquées

David Makowski, Hervé Monod

Analyse statistique des risques agro-environnementaux

Études de cas

Makowski • Monod



Analyse statistique des risques agro-environnementaux

$$\phi(n) = \left(1 - \frac{1}{12}\right) \left(1 - \frac{1}{n}\right)$$

$$P(A) = \frac{25}{216} \text{ et } P(B)$$

$$(\forall B \in \beta_{\mathbb{R}}) \quad P_X(B) = P(X^{-1}(B)) \\ = P(\{\omega \in \Omega \mid X(\omega) \in B\})$$

Springer

$$P(A_2) = 1 - P(\overline{A_2}) = 1 - \left(\frac{35}{36}\right)^{24} \approx 0,491.$$